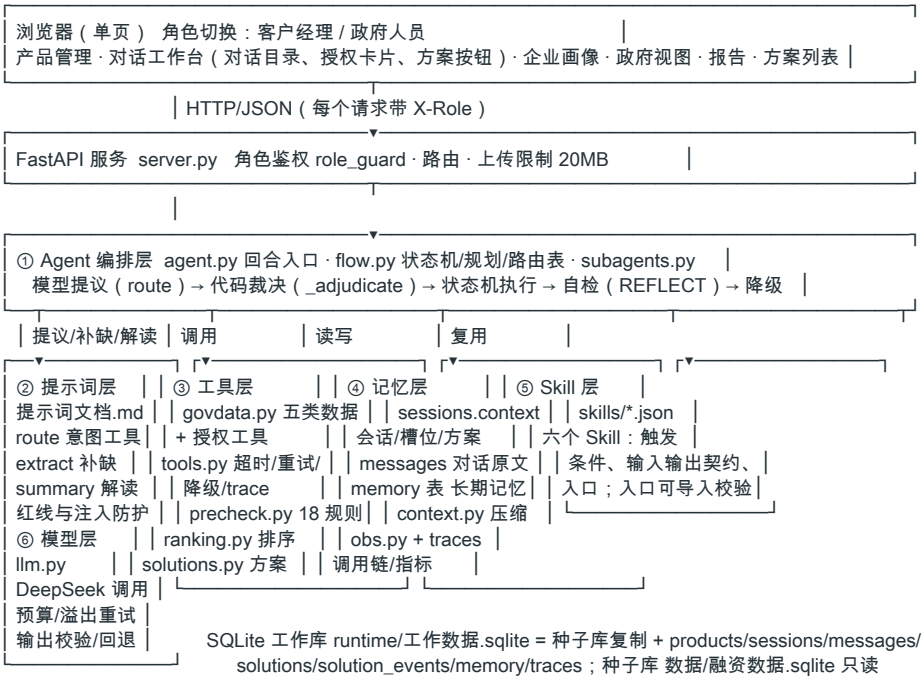
企业智能融资匹配平台 · 技术方案

本方案前 9 章对应评审要求的 9 个主题；第 10 章起是配套说明（接口、数据模型、角色、模型调用、上下文、编排、可观测、启动、测试）。

1. 总体架构图

1.1 分层视图（六层）



模型层与提示词层是可选且受限的：没配密钥或调用失败时，编排层回退本地规则，整条链路照常运行。

1.2 一个回合怎么走

用户一句话 → 规则解析(nlu) → [配了密钥且单句：模型提议意图与工具(route)，代码裁决] → [缺项才调模型补缺(extract)，须过代码校验]
→ 路由(ROUTE) → 规划(plan)
→ COLLECT 缺项追问 → LOOKUP 查企业 → AUTH 授权闸门 → CONSISTENCY 区域/行业一致
→ FETCH 四类数据分次调取 → PRECHECK 逐产品预审 → RANK 排序 → REFLECT 自检(不过则重做/降级)
→ SAVE 建单「待确认」 → EXPLAIN 模型解读(可选) → END

任何一步遇到「缺项 / 未收录 / 待授权 / 材料不一致 / 失败」都直接转到 END，后面的步骤在计划里标「跳过」并写原因。

1.3 四层职责

层	职责	关键点
Agent 编排层	决定走哪一步、谁来做	模型提议意图与工具，代码裁决；流程由状态机转移表控制；子 Agent 职责单一
提示词层	约束模型能做什么	提示词集中在提示词文档，含输出格式、红线、注入防护；改文档即改行为
模型层	调用 DeepSeek	固定模型、token 预算、溢出重试、输出校验、失败回退、成本统计
工具层	取数、预审、排序、存单	参数固定、超时 8 秒、重试 2 次、授权错误不重试；结果直接决定结论
记忆层	多轮不丢、会话不串、可查可纠	结构化记忆永不压缩；对话原文可压缩；长期记忆可见可改
Skill 层	把可复用流程沉淀为声明	触发条件 + 输入输出契约 + 入口；启动时校验入口可导入

预审、排序、统计、授权闸门是代码与配置，模型改不了。模型承担三件事：提议意图与工具、补缺字段、写解读，所有输出都经代码裁决或校验（见第 11、14 章）。

2. 产品 PDF 抽取入库

2.1 抽取时机

只在上传时抽取，逻辑写在服务里（POST /api/products/upload，批量入库用 POST /api/products/upload-samples），由 extractor.extract_product 完成。问答时不再打开 PDF，预审只查产品表。

2.2 抽取方法

用 pdfplumber 取每页的表格和「第X条」标题坐标，把每张表归到其上方最近的标题下，再按条款解析。

2.3 字段设计（products 表）

类别	字段	来源条款
标识	产品编号、产品名称、机构	封面/标题
额度	amount_min/max（万元）	第五条
利率	rate_min/max（年化，%）	第五条
期限	term_min/max（个月）	第三条
适用范围	purposes、regions、industries（多值；「不限」存为空表示不否决）	第三条（用途）、第四条（区域、行业）
产品属性	guarantees、repay_method、revolving、subsidy_supported	第五条
准入条件	conditions：纳税等级、参保人数、成立年限、纳税额、科技资质、纳税人资格	第六条
未识别条款	extra_conditions	第六条里不认识的条件
追溯	source_map（每个数字对应的条款与原文）、intro_text、upload_count、uploaded_at	—

2.4 口径取舍：条款优先于导语 / 附章

1. 只读

   第三条（用途、期限）、第四条（区域、行业）、第五条（额度、利率、担保、还款、是否循环、贴息）、第六条（准入条件）。

1. 不读

   导语、附章、第十条至第十六条里的数字（如导语里「最高千万级」的宣传话术）。同一产品导语与条款冲突时，以条款为准；

   source_map

   记录每个数字来自哪一条。

1. 导语原文只存

   intro_text

   供查看，不参与预审。

2.5 覆盖、失败与泛化

1. 同一产品编号再次上传：覆盖原记录并累计上传次数。
1. 缺要素、非 PDF、损坏文件：整份拒绝，不写半条记录，返回缺失项。
1. 第六条里不认识的条款存入

   extra_conditions

   ，预审时该产品最多判为「需人工复核」，不会被当作通过。

1. 区域、行业、用途、担保方式都按多值解析；第六条按条件名映射到规则，新增产品不改代码。

3. 对话录入

3.1 必填项与追问

必填四项：企业、融资金额、期限、用途。缺任何一项，先追问，追问时不调数据（状态机在 COLLECT 直接结束，FETCH 记为跳过）。担保方式、主条件（利率优先 / 额度优先，未说时默认利率优先）可选。

3.2 条件增量修改

1 会话上下文（`sessions.context.slots`）保存已识别的条件；后一句只改说到的条件，其余沿用。

1 同一待确认方案内改条件是**更新原单**，不重复建单。

1 例：「改成额度优先」只改主条件，企业、金额、期限、用途保持不变。

3.3 解析口径

项	规则
金额	按万元；支持「亿」「元」换算和中文数字；出现多个金额或数值无效则追问
期限	只接受「个月」。只说天、年、半年时追问月数，不折算（360 天不当 12 个月，1 年不当 12 个月）
用途	与条款用词完全一致。「流动资金」与「周转资金」互不代替；没出现在任何产品里的用途照常预审，全部判用途不符并提示
企业名称	必须与 enterprise.enterprise_name 完全一致；简称、漏字、多写「集团」都按另一家处理
区域 / 行业	对话另说了区域或行业且与 enterprise.region / industry 不一致 →「材料不一致」，停止匹配，不按任何一边推荐；只提注册地址、经营范围不算改写

3.4 分支结论

1 未收录：回复「未收录」并提示「无公司数据，需提供数据源」，状态`not_found`，不编造数据。

1 待授权：`data_authorization`不是「已授权」时停下，与用户交互授权（见 4.2）。

1 准入符合产品按 6.2 排序，名单最多 3 个，客户经理直接确认或放弃，不需要选定某一个产品；无准入符合：明确写「无准入符合产品」。

1 一条消息里可有多个企业和动作（确认、先别确认、放弃、打开政府视图/报告），按句分组依次处理。

3.5 模型的位置

意图识别：单句输入且配了密钥时，模型先提议意图与工具，由代码裁决（见 14）。字段解析以规则为准。配置了密钥且必填项仍缺时，模型只补规则没识别出的字段，补出的值必须通过代码校验（企业须与库内完全一致且原话逐字出现、期限须原话含「N个月」、用途须在条款用语表内且逐字出现）。天/年这类规则已判定有问题的字段，模型不得补。

4. 政务数据调取

4.1 五次分次调取

次序	工具	数据	说明
1	query_enterprise	工商	先查，决定是否收录、是否授权
2	query_tax	税务	授权后才允许
3	query_social_security	社保	授权后才允许
4	query_judicial	司法	授权后才允许
5	query_financing_history	历史融资	授权后才允许

五个工具分次调用，每次记入 trace（参数、返回摘要、耗时、重试次数）。工具返回只含 rules.json 的白名单列和仅展示列；统一社会信用代码、法定代表人脱敏。

4.2 授权闸门：非「已授权」整单结论「待授权」

1 授权闸门写在

工具里

：

enterprise.data_authorization

不是「已授权」时，后四个工具直接拒绝读取（抛

AuthorizationError

，不重试）。整单结论「待授权」，不预审，不出方案。

1 未授权企业在会话上下文里记

pending_auth

（企业编号、名称）。

1 两种入口，同一处理

（

agent._auth_decision

）：对话里回复「已授权 / 同意授权 / 不授权」（

nlu.parse_auth

，否定优先）；或点页面授权卡片（

POST /api/conversations/{sid}/authorize

，body

{"decision":"grant|deny"}

，没有待授权事项返回 409）。

1 同意：

govdata.grant_authorization

把授权状态、授权编号

AUTH-<企业编号>

、授权日期、授权范围写进

工作库

的

enterprise

表（种子库不动），再按会话里已有的条件继续预审；授权后同企业再次预审不再询问。

1 拒绝：清除待授权状态，不调取任何数据，不生成方案。

1 边界：授权为操作人员口头/按钮确认，不校验授权凭证；接入真实授权核验只需替换

grant_authorization

。

4.3 失败降级

取数超时 8 秒、重试 2 次；仍失败的来源记入 facts.failed，按「未获取」处理（见 5.3），不编造数据。可用 FIN_FAULT=tax:1 模拟失败。

5. 准入预审

5.1 参与预审的列白名单

Facts.get 只允许读取 config/rules.json 的 whitelist 里的列，读白名单外的列直接抛错，干扰列在物理上进不了规则。

表	白名单列
enterprise	enterprise_name、founded_date、business_status、region、industry、data_authorization、is_high_tech、is_specialized、invention_patent_count
tax	tax_credit_rating、taxpayer_type、tax_arrears、tax_paid_12m_wan
social_security	insured_count、social_security_arrears
judicial	is_dishonest、is_enforced
financing_history	overdue_unsettled

不参与预审（只在画像里展示或完全不用）：员工人数、核准日期、注册地址、经营范围、行业代码、集团、external_score、企业类型、实缴资本、营业收入、纳税信用描述等。

5.2 18 条规则的判定与原因输出

规则顺序与文案来自 config/rules.json，输出原因按此顺序，一个产品命中的原因全部写出。「条件类」规则只在产品第六条写了该条件时才评估。

#	规则（原因文案）	来源	判定	类型
1	经营状态不符	工商	business_status = 「在营」才通过	条件类
2	税务欠缴	税务	tax_arrears=1 不符	条件类
3	社保欠缴	社保	social_security_arrears=1 不符	条件类
4	逾期未结清	历史融资	overdue_unsettled=1 不符；库里无历史融资视为无逾期，已结清不触发	条件类
5	需求金额低于下限	需求	金额 < amount_min	必评
6	需求金额高于上限	需求	金额 > amount_max	必评
7	期限不在产品区间	需求	不在 term_min–term_max	必评
8	用途不符	需求	用途不在 purposes（用词完全一致）	必评
9	区域不符	工商	产品区域为「不限」通过；否则 region 须在其中	必评
10	行业不符	工商	同上，看 industry	必评

#	规则（原因文案）	来源	判定	类型
11	纳税等级不足	税务	等级 A>B>M>C，不低于要求通过（等于通过）	条件类
12	参保人数不足	社保	insured_count ≥ 要求（等于通过）	条件类
13	成立年限不足	工商	按周年计算，基准日 2026-09-23，未到周年日不算满	条件类
14	纳税额不足	税务	tax_paid_12m_wan ≥ 要求（等于通过）	条件类
15	失信限制	司法	is_dishonest 或 is_enforced 任一为 1 即不符	条件类
16	科技资质不符	工商	高新、专精特新、有效发明专利 ≥1 三项满足其一	条件类
17	纳税人资格不符	税务	taxpayer_type 须等于要求	条件类
18	担保方式不符	需求	仅当客户指定担保方式时评估，须在产品 guarantees 内	可选

每条判定输出 {规则, 状态(pass/fail/unknown), 说明文本, 依据字段}，说明里带具体数值与条款（如「纳税等级 B 低于要求 A（第六条）」）。

5.3 未获取字段 → 需人工复核

1 字段为空或取数失败记 unknown，标注来源（如「社保未获取」），不写成正常、无欠税、无逾期。

1 结论：任一规则 fail →「准入不符」（有未获取项时一并注明）；无 fail 但有未获取，或有未识别的第六条条款 →「需人工复核」；全部 pass →「准入符合」。

1 已入库的所有产品都给出结论。

1 自检（REFLECT）保证：「准入符合」的产品不得有失败或未获取的规则，否则重做并降级为「需人工复核」。

6. 推荐排序

6.1 两种主条件的排序规则

只对「准入符合」的产品排序。

主条件	排序键（依次比较）
利率优先（默认）	利率上限 ↑、额度上限 ↑、产品编号
额度优先	额度上限 ↓、利率上限 ↑、产品编号

产品编号按自然序比较（PRD_2 在 PRD_10 前）。

6.2 名单规则

1 只对结论为「准入符合」的产品排序。

需人工复核、准入不符都不进名单。

1 名单最多 3 个

（

max_recommend

）。准入符合超过 3 个时，其余产品仍写在预审明细里，结论保持「准入符合」，不改成不符；回复里注明其余 N 个。

1 一个都没有时，回复明确写「无准入符合产品，推荐名单为空」。

1 排序用的利率上限、额度上限取产品表中从说明书第五条抽出的数字，不取导语。

1 每个上榜产品都带额度区间和利率区间，并标注「产品库区间，不是授信审批结果」；不输出单一执行利率，不输出建议批准（模型摘要里含「建议批准」「批准」等词会被丢弃）。

1 对话工作台

不需要人工选定产品

：准入符合 1 个、多个或 0 个，都是直接「确认」或「放弃」。确认保存的是整份预审结果与推荐名单，不提交贷款申请。

6.3 区间口径

每张推荐卡写：额度区间（min–max 万元）、年化利率区间（x%–y%）、担保方式、还款方式。数字全部取自产品表（第五条）。

1 利率、额度是

产品库公示区间

，不是授信审批结果，也不是单一执行利率；卡片与回复里都标明。

1 不输出单一执行利率，不输出「建议批准」。

1 企业行业为制造业且产品支持贴息时标「可申请制造业贴息（尚未兑付）」。

7. 画像、确认与统计

7.1 企业画像：四块事实与来源

工商、税务、社保、历史融资四块（另附司法）。每条事实带来源「融资数据.sqlite · 表.字段」，并标注是否参与预审；未获取保持「未获取」。未授权企业只展示工商，并提示待授权（GET /api/profile）。

7.2 三种方案状态

状态	进入方式	说明
待确认	预审完成自动建单	可改条件（更新原单）；不进入政府视图和报告
已确认	经理确认	进入政府视图与报告；不需要选定产品；无准入符合产品也可确认；确认只保存对接单，不提交贷款申请
已放弃	经理放弃	不进入政府视图和报告

状态写库，刷新后保留；状态变更记入 solution_events；终态不再变更。

7.3 政府视图四指标口径

只统计已确认方案；已确认数为 0 时写「暂无已确认方案」，不显示百分比。

指标	口径
区域融资热度	按企业区域统计已确认方案数，降序，同数按首次出现
行业分布	按企业行业统计已确认方案数

指标	口径
产品排行	已确认方案里每个准入符合的产品各计 1 次（不限于名单前 3 个）；需人工复核和准入不符不计
供需匹配率	分子=准入符合产品 ≥1 个的已确认方案数，分母=已确认方案数，同时给出分数与百分比

7.4 报告三节

企业、产品、区域三节，数字与政府视图同源（同一套 _confirmed() 口径），企业节列出每家企业「准入符合产品」（已确认方案里准入符合的产品名称，去重，没有则写「无」）；产品节和区域节的最后一列是「企业名称」（产品节：该产品准入符合的企业；区域节：该区域的企业，均去重）。接口仍附带 plans（方案编号、主条件、准入数、决定时间）供追溯，页面不显示。

8. 工程能力

8.1 记忆系统

层	存储	内容	管理
会话记忆	sessions.context	企业、已识别条件、当前方案、授权状态、压缩摘要	随会话；多轮增量修改靠它
长期记忆	memory 表，作用域 session:<会话> 与 global	每次预审结论、已确认结论、默认口径（基准日、期限口径、用途口径、名称口径、主条件默认）	GET/PUT/DELETE /api/memory、「记忆」面板可查看、纠正、清除；对话里可说「查看记忆」「清除记忆」「刚才的结果」

默认口径作为 global 记忆展示，用户纠正后以用户值为准。压缩与裁剪见第 13 章。

8.2 会话与资产管理

1 会话

：每个对话一个

sessions

记录，消息与调用链落

messages

，会话编号由服务端生成；左侧目录按企业名命名，可新增对话，一个会话支持多轮，刷新后恢复历史、授权卡片和方案按钮（见第 12 章）。

1 方案资产

：

solutions

保存请求、预审快照、推荐名单、状态；

solution_events

记录建单、改条件、确认、放弃；可检索（

/api/solutions?status=

）、可追溯、可回放。

1 产品资产

：

products

带来源条款与上传次数，支持导出 CSV、删除。

1 调用链资产

：

traces

表按回合保存，可按会话、状态查询（见第 15 章）。

8.3 工具调用

1 工具清单：

query_enterprise / tax / social_security / judicial / financing_history

、

grant_authorization

、

query_product_table

、

rank_products

、

save_solution

、

select_product

、

gov_view_stats

、

memory_list

，模型工具

llm_extract / llm_summary

。

1 参数构造固定，无冗余调用；同一回合内每类数据只取一次。

1 tools.call_tool

：线程池执行，

超时 8 秒、失败重试 2 次

；授权错误不重试；仍失败返回降级信息。

1 结果直接决定后续结论：取数失败的来源按「未获取」降级，受影响产品判「需人工复核」或在不符里注明。

1 trace 记录每次调用的工具名、参数、返回摘要、耗时、重试次数；大参数与大返回截断到 300 字并注明原长。

8.4 Skill 管理

1 skills/*.json

六个 Skill：抽取产品要素、调取政务数据、执行准入预审、排序推荐、保存融资对接单、统计政府视图与报告。

1 每个 Skill 有

id、name、trigger、input、output、entry、contract

；

skills.py

启动时校验必填字段，

check_entries()

校验入口函数可导入。

1 trace 记录每回合用到的 Skill；

GET /api/skills

可查看。新增能力 = 新增一个 JSON 声明 + 一个入口函数。

9. 鲁棒性与可解释性设计、合规性设计

9.1 鲁棒性

场景	处理
空白、乱码、纯符号输入	提示补充信息，不崩溃
超长输入	超过 4000 字截断并记录
金额为 0、期限单位不对、多个金额/期限	追问，不猜测
损坏或非 PDF 的产品文件	整份拒绝，不写半条记录
外部调用失败	8 秒超时、重试 2 次，来源按未获取降级；FIN_FAULT=tax:1 可演示
模型失败、超时、输出不合规	回退本地规则，对话不受影响
单点异常	捕获并定位到出错节点，不改动任何方案，回复里带调用链编号
自检不通过	重做一次；仍不通过则把有疑问的产品降级为「需人工复核」
并发与重复操作	方案状态终态不再变更；REST 确认、页面按钮与对话确认共用同一套状态流转

9.2 可解释性

1 每个结论给出命中的规则、表名、字段名、数值；未获取项单独标注；每个产品数字可追溯到产品说明书的条款。

1 每回合有调用链：状态路径、计划、各节点耗时、工具与模型调用、降级处理、出错节点（见第 15 章）。

1 同输入多次运行结论与格式一致：解析、预审、排序均为确定性代码；模型

temperature=0

且只做补缺与解读。

1 模型解读必须能被结构化结果印证：出现输入里没有的数字或「批准、放款」等字样即丢弃。

9.3 合规性

1 数据授权

：未授权企业不调取税务、社保、司法、历史融资，不预审；授权结果只写工作库。

1 脱敏与最小外送

：统一社会信用代码、法定代表人在画像与日志里脱敏；仅在配置了

DEEPSEEK_API_KEY

时调用 DeepSeek，外送内容只有用户本轮原话、必要的会话上下文和预审结果摘要（需求、产品名、结论、原因），不外送

信用代码、法定代表人及税务/社保/司法/历史融资明细；不配密钥则全程本地。

1 口径合规

：预审只用白名单列，不使用 external_score、group_name 等；利率额度只给公示区间，不输出单一执行利率、不「建议批准」；确认不提交贷款申请、不向银行发送。

1 内容合规

：对造假、规避风控类请求拒绝；不编造法规条款，依据只有已授权政务数据和产品说明书条款。

1 评测合规

：标准结果只在自测比对脚本里读取，不写入提示词或系统，不用于预填结果；回归用例为自建，不含任何标准结果。

1 权限

：客户经理与政府人员分权，越权接口 403（见第 10.3 节）。边界：角色由页面声明，没有登录鉴权。

---

10. 接口、数据模型与角色

10.1 接口一览

接口	用途
POST /api/chat	发送一句话，返回回复、结果、trace、pending_auth、title、solution
GET/POST /api/conversations、GET /api/conversations/{sid}	对话目录、新增对话、对话详情与消息
POST /api/conversations/{sid}/authorize	页面授权（grant/deny）
POST /api/conversations/{sid}/solution	页面方案操作（select/confirm/abandon）
GET /api/sessions、GET /api/sessions/{sid}/messages	原始会话与消息记录
POST /api/products/upload、/upload-samples、GET /api/products、/export.csv、DELETE /api/products/{code}	产品管理
GET /api/profile	企业画像
GET /api/solutions、/{id}，POST /{id}/confirm、/{id}/abandon	方案列表与状态
GET /api/gov-view、/api/report	政府视图、报告
GET/PUT/DELETE /api/memory、GET /api/skills、POST /api/admin/reset	记忆、技能、重置
GET /api/traces、/api/traces/{id}、/api/metrics	调用链、聚合指标（仅客户经理）

10.2 数据模型（工作库）

products（产品要素与来源）、sessions（会话上下文）、messages（消息与 trace）、solutions（方案：请求、预审快照、推荐名单、状态）、solution_events（状态事件）、memory（记忆）、traces（调用链：耗时、token、成本、状态、出错节点、完整 body）；enterprise 等业务表由种子库复制，授权只改工作库中的 enterprise 授权字段。

10.3 角色与权限

页面右上角「客户经理 / 政府人员」切换，当前角色存在浏览器 localStorage，每个请求带 X-Role 头（缺省按客户经理，兼容脚本）。

角色	可见页面	接口权限
客户经理	产品管理、对话工作台、企业画像、政府视图、报告、方案列表	读写：产品、对话、企业画像、报告、方案；政府视图、调用链、指标只读
政府人员	企业画像、政府视图、报告、方案列表	全部只读（确认/放弃、对话、产品上传均 403）

1 服务端中间件 role_guard（server.py 的 ROLES 表）按路径前缀和 HTTP 方法判定，越权 403，未知角色 400；前端同时隐藏无权页面，手动改地址栏会被拉回该角色的第一个页面。

1 「记忆与技能」页及其接口（/api/memory、/api/skills、/api/admin）目前不属于任何角色，两个角色都访问不到。

1 对话里说「打开政府视图」两个角色都可以。

1 静态页面与脚本带 Cache-Control: no-cache；前端事件绑定用容错的 $o()，页面元素被删除或注释时静默跳过。

11. 对话模型与提示词

1 模型：finmatch/llm.py 中 MODEL = "deepseek-flash"（DeepSeek-V4.1-Flash 的接口名，页面显示 deepseek-v4.1-flash）写死，不读环境变量；DeepSeek OpenAI 兼容 /chat/completions，temperature=0，超时 20 秒，失败不重试直接回退规则。密钥读 .env/环境变量 DEEPSEEK_API_KEY，未配置则不调用。

1 用途一：补缺

。仅当必填项（企业、金额、期限、用途）规则与会话记忆都没覆盖时调用；规则已有值或已判定有问题（如只说天/年）的字段不补；补出的值必须通过 3.5 的校验。仅单句输入时启用。

1 用途二：解读

。对已算好的结果生成 ≤200 字解读，附在回复末尾；含输入里没有的数字（按数值比较）或「批准/放款」等字样则丢弃。

1 用途三：意图识别与工具选择（route）

。单句输入且配了密钥时，每回合先调一次，输出

intents

（需求、确认、放弃、暂不确认、政府视图、报告、画像、查看记忆、上一单结论）与

tools

；形式校验在

llm.route

（取值须在枚举内，工具须在所提意图的允许范围内），裁决在

agent._adjudicate

。

1 模型不参与预审、排序、授权闸门、区域/行业一致性判断。trace 里记录

llm_route

、

llm_extract

、

llm_summary

，含 token、耗时、估算成本。

1 提示词唯一来源

：

提示词文档.md

（

prompt:extract

、

prompt:summary

），改文档即改行为。

12. 会话历史与方案按钮

1 左侧目录保存全部会话（

sessions

/

messages

），一个会话可多轮；目录标题取识别到的企业名，没有企业叫「新对话」，按最近更新排序，待授权的带标记；「+ 新增对话」新建独立会话，企业和条件互不串。

1 浏览器把当前会话编号存在

localStorage

，刷新后回到上次对话，回放消息，并恢复授权卡片和方案操作卡片。

1 方案操作卡片由

/api/chat

与

GET /api/conversations/{sid}

返回的

solution

渲染：卡片显示准入符合数和推荐名单（无则写「无准入符合产品」），只有「确认方案」「放弃」两个按钮，不需要选产品。按钮调用

POST /api/conversations/{sid}/solution

，仅客户经理可用。

13. 上下文管理（finmatch/context.py）

问题	做法
多轮记忆是否保留	两层：①结构化记忆（企业、槽位、当前方案、授权状态）存在 sessions.context，与对话条数无关，永不丢；②对话原文落 messages，页面可回看。「后一句只改说到的条件」靠第①层
超长对话如何压缩裁剪	消息超过 16 条触发压缩：旧消息由规则（不调模型，避免压缩时编造）写成摘要存入 ctx.summary（企业、当前条件、当前方案、更早 N 次提问节选），只保留最近 8 条原文。页面回看只取最近 200 条
送模型的上下文	有 token 预算（约 1500）：先丢最旧原文，再截断摘要，仍超限则不带上下文；整个请求超 6000 token 本地拒发
工具大结果怎么截断回填	trace 里工具参数与返回统一截断到 300 字并注明原长；送模型的结果视图里未通过产品最多 12 条、每条原因最多 4 个，多余的写「另 N 项已省略」；产品明细、事实数据不进模型
多会话是否隔离	会话状态按 session_id 存取，历史、方案、会话级记忆都带会话键；测试断言 B 会话看不到 A 会话的企业与条件
上下文溢出会不会崩	输入超 4000 字截断并记录；模型接口报上下文溢出时去掉上下文重试一次，仍失败回退规则；压缩/裁剪函数异常一律吞掉并降级，不影响本回合

14. Agent 编排（finmatch/flow.py + subagents.py）

1 状态机

：

flow.TRANSITIONS

是转移表，流程由它控制而不是提示词硬编。主干

START → PARSE → ROUTE → 需求流水线/ACT/INFO → END

；需求流水线

COLLECT → LOOKUP → AUTH → CONSISTENCY → FETCH → PRECHECK → RANK → REFLECT → SAVE → EXPLAIN → END

。追问、未收录、待授权、材料不一致、失败都转到 END 并记原因；非法转移抛

FlowError

，会被定位到具体节点。

1 规划—执行—反思闭环

：ROUTE 时

make_plan

按识别出的意图列出步骤（含负责的子 Agent 与工具）；执行时逐步打勾，没走到的标「跳过」并写原因；REFLECT 自检后若不通过，回到 PRECHECK 重做，最多 1 次；仍不通过则

降级

：有疑问的产品改判「需人工复核」。

1 自检不变量

：预审结果数=产品数；排序准入数=预审准入数；推荐名单只含准入符合产品；准入符合的产品不得有失败或未获取的规则；金额、期限合法。

1 子 Agent

（职责单一，输入输出为结构化数据）：DataAgent（取数）、PrecheckAgent（预审）、RankAgent（排序）、ReflectAgent（自检/降级）、ExplainAgent（模型解读）。

1 多工具路由：模型提议、代码裁决

：

flow.ROUTES

记录每个状态的子 Agent 与可用工具，写入计划与 trace。意图由模型提议（

llm.route

）并与规则结果合并，裁决规则（

agent._adjudicate

）：

1 「提出需求」与只读意图（政府视图、报告、画像、记忆、上一单结论）可采纳，采纳后仍走原有流水线与硬规则；

1 「确认、放弃、暂不确认」会改变方案状态：规则没从原话识别出时

不执行

，只提示用户明确表述或点按钮；

1 模型提议的工具超出所提意图允许范围的被丢弃；实际执行的步骤仍由状态机与路由表决定，模型的工具清单只记入 trace（

llm_route

）供审计；

1 无密钥、调用失败、提议不合法时回退纯规则。

1 失败重试与降级

：工具层超时 8 秒、重试 2 次，授权错误不重试，失败来源按未获取降级；模型失败回退规则；自检失败重做后降级；单点异常被捕获并定位节点，不改动任何方案。

1 说明：子 Agent 是同进程内的角色划分（函数级拆分），不是独立进程或多模型协作。

15. 可观测（finmatch/obs.py）

1 调用链

：每个回合一个

trace_id

，含状态路径

flow

、计划

plan

、节点耗时

spans

（节点、子 Agent、毫秒、状态）、工具调用、模型调用

llm

、命中规则、降级处理

degraded

、出错节点

error

。落库到

traces

表，页面「调用过程」展开可见，也可按编号还原。

1 token / 耗时 / 成本

：模型调用记录接口返回的

usage

（无则按字数估算并标注

usage_source

）、耗时、成本；成本是估算（元/百万 token，

llm.py

的

PRICE_IN/PRICE_OUT

或环境变量

LLM_PRICE_IN/OUT

，默认值为占位，以账单为准）。

1 出错定位

：异常记到具体节点和子 Agent（

error.node/agent/type/message

），回复里带节点名和调用链编号；

status

分 ok / degraded / error。

1 接口

：

GET /api/traces?session_id=&status=&limit=

、

GET /api/traces/{trace_id}

、

GET /api/metrics

（回合数、成功/降级/出错、平均/p50/p95 耗时、token、成本、各节点平均耗时、出错节点分布、模型调用成功率）。仅客户经理可用，政府人员 403。

1 回归评测集

：

tests/eval_cases.json

（12 条自建用例，覆盖多轮记忆、天/年追问、用途用词、未收录、授权、多产品选择、多会话隔离、40 轮长对话、超长输入）+

finmatch/regress.py

引擎；断言结论、名单、状态路径、调用链无错误。命令行

scripts/regress.py

（默认临时库、不调真实模型，失败时打印 trace 编号）；pytest 里

test_regression_suite

同样会跑。用例不含公开/非公开测评集的标准结果。

16. 一键启动

./start.sh：创建 .venv、安装依赖、生成 .env（从 .env.example）、启动 uvicorn（默认 8000，PORT 可改）、产品表为空时自动入库示例 PDF、打开浏览器。

17. 测试

共 53 项：tests/test_system.py（33 项：产品抽取、预审规则、排序与并列规则、对话解析、确认与统计、授权、名单最多 3 个且带区间标注、无产品与未收录提示、对话目录、角色权限、模型校验与回退、方案按钮）+ tests/test_agent_ctx_obs.py（20 项：回归评测集、模型提议与代码裁决（只读意图采纳、确认类意图不越权、非法提议回退）、上下文压缩与隔离、截断与溢出、状态机与自检降级、出错定位、token/成本记录、调用链接口）。测试默认清除 DEEPSEEK_API_KEY，不调真实模型。运行：.venv/bin/python -m pytest tests -q；回归评测：.venv/bin/python scripts/regress.py。