企业智能融资匹配平台 · 测试报告

1. 公开测评集 15 题自测（以标准结果为基准）

基准：数据/公开测评集_含标准结果.xlsx，共 15 题、13 个会话。标准结果只在 scripts/compare_gold.py 里读取，不进入系统和提示词。
方法：FIN_RUNTIME_DIR=/tmp/ev/rt .venv/bin/python scripts/run_eval.py（独立运行库、上传 11 份 PDF、逐题提问），再用 scripts/compare_gold.py 与标准结果逐项比对。
日期与环境：2026-10-24，macOS，Python 3.9.6。两种模式各完整跑一遍：规则模式（不配密钥）、对话模型模式（DeepSeek deepseek-flash 已启用）。

1.1 量化结果

维度	规则模式	模型模式
整题一致	15 / 15（100%）	15 / 15（100%）
有名单类题：主条件	11 / 11	11 / 11
有名单类题：准入符合数	11 / 11	11 / 11
推荐名单（集合）	11 / 11	11 / 11
推荐名单（含顺序）	11 / 11	11 / 11
产品级结论（符合 / 不符 / 需人工复核）	121 / 121（100%）	121 / 121（100%）
产品级结论 + 原因集合	121 / 121（100%）	121 / 121（100%）
无名单题关键点（第 6、7、8、13 题）	15 / 15	15 / 15
单题耗时（均值 / 中位 / P90 / 最大）	1374 / 1411 / 2083 / 2896 ms	1371 / 1505 / 1854 / 2986 ms
全部 15 题耗时	20.6 s	20.6 s

产品级 121 = 11 道有名单的题 × 11 份产品。两种模式结果完全相同，说明模型只做辅助（补缺、摘要、意图提议），不改变判定。

变更说明：上一版报告是 13/15。差异在第 7、8 题：当时规则要求准入符合 2 个以上时先由操作人员选定一个产品才能确认，批量「确认」被拦下，已确认数、视图和报告与标准不符。现在改为对话工作台不需要选定产品（名单按排序规则最多列 3 个，直接确认或放弃），这两题恢复一致。

1.2 逐题明细

比对脚本输出见 自测结果/公开测评集逐题比对.md 和 自测结果/CtrlShiftAI_赛题05_公开测评集逐题比对表.xlsx，公开集会话记录见 会话记录/。以下「要点」为每题的验证点。

题号	会话	主条件	准入符合数	推荐名单	要点
1	A	利率优先	1	订单融资	订单备货只有订单融资接；流动资金类产品用途不符
2	B	利率优先	3	税信e贷 / 日常经营贷 / 快e周转	参保 48 人（不用员工人数）；已结清逾期不触发；税信e贷上限取条款 300 万
3	B	额度优先	3	快e周转 / 税信e贷 / 日常经营贷	同一单更新主条件
4	C	利率优先	0	空	税务欠缴，纳税信用描述不能抵消
5	D	利率优先	0	空	社保为空：未获取，4 个无硬性不符产品判需人工复核
6	E	—	—	—	未收录，不画像不匹配
7	F	利率优先	—	—	已确认 2 笔；区域澄川市 2；制造业 1、批发和零售业 1；产品排行各 1；匹配率 1/2
8	F	—	—	—	报告三节与视图一致，待确认和已放弃不出现

题号	会话	主条件	准入符合数	推荐名单	要点
9	G	利率优先	2	日常经营贷 / 快e周转	参保 9 人
10	H	利率优先	1	快e周转	成立 2024-09-24 未满 2 年、满 1 年；不用核准日期
11	I	利率优先	2	惠农e贷 / 快e周转	惠农e贷条款用途含流动资金，导语不算
12	J	利率优先	0	空	逾期未结清与金额高于上限同时写出
13	K	—	—	—	材料不一致，停止匹配
14	L	利率优先	2	北原研发贷 / 科创信用贷	按区域字段北原市，不按注册地址
15	M	利率优先	0	空	5000 万高于全部上限

2. 政府视图与报告自测

第 7、8 题后的视图与标准结果逐项一致（规则模式与模型模式相同）：

指标	标准结果	系统输出	一致
区域融资热度	澄川市 2	澄川市 2	是
行业分布	制造业 1，批发和零售业 1	制造业 1，批发和零售业 1	是
产品排行	税信e贷 1，日常经营贷 1，快e周转 1	同左	是
供需匹配率	1/2	1/2	是

正满金属制品有限公司（待确认）和澄川市禾青蔬菜专业合作社（已放弃）不进入任何一项。产品排行里，百汇商贸全部不符，不计。报告企业、产品、区域三节与视图同源，并列出对应方案。自动化测试覆盖：无已确认方案时为「暂无已确认方案」；无准入符合产品的方案可确认，匹配率 0/1；已放弃方案不能再被确认。

3. 自动化测试

.venv/bin/python -m pytest tests -q：53 项全部通过（test_system.py 33 项、test_agent_ctx_obs.py 20 项），约 55 秒，不调用真实模型。覆盖：

1. 产品抽取：条款数字、导语不入库、同编号覆盖、非 PDF/损坏文件拒收。
1. 预审：超过 3 个准入符合仍保持符合；未授权不调数据；企业名称精确匹配；期限单位追问；用途用词；担保方式；社保欠缴、失信、纳税等级、成立年限、科技资质等边界企业；区域/行业声明一致性；金额解析与极端值。
1. 确认流程与统计口径；多个准入符合产品时无需选定、直接确认；名单只含准入符合、最多 3 个，利率优先 / 额度优先及并列时的排序（含产品编号自然序）；每个上榜产品带区间与「产品库区间，不是授信审批结果」，不输出建议批准；方案列表「人工确认的产品 / 确认时间」；页面按钮不再接受 select 操作。
1. 上下文与编排：多轮记忆、压缩与截断、会话隔离、状态机、重试降级、意图提议与代码裁决、trace 与成本统计。
1. 鲁棒性：空白、乱码、超长输入、不当请求、法规请求；工具失败重试与降级；同输入结论一致；白名单越权读取报错；敏感字段脱敏。

4. 扩展自测（自建，非官方非公开集）

tests/扩展自测题.md 自建 15 题（新金额、期限、用途、担保方式、主条件组合，以及各类边界企业），会话记录在 自测结果/扩展自测会话记录/。这些题没有官方标准结果，只用于检查系统对未见组合能直接给出预审结论，不计入一致题数。

5. 性能

见 1.1 的耗时行：公开集 15 题，规则模式与模型模式合计均约 20.6 s，中位约 1.4–1.5 s，最大 3.0 s（含授权后分次调取五类数据，模型模式再含 1–3 次模型调用）。不含 PDF 抽取（11 份约数秒）。上一版记录的「单题 4–20 ms」是未接模型、未做授权调取时的数字，不再适用。

6. 非公开测评集

输入：数据/06_非公开测试集_现场加试/01_非公开测试集_输入_现场提供.xlsx，共 30 题（第 16–45 题），仅含输入、不含标准结果；其中第 22、23 题为同一会话的连续对话。

方法：使用隔离的临时工作库、本地规则模式，重新抽取入库 11 份产品说明书，再按题号运行。项目启动时会从 .env 读取密钥，因此用空值显式关闭模型调用：
日期与环境：2026-10-25，macOS，Python 3.9.6。

```
DEEPSEEK_API_KEY='' FIN_RUNTIME_DIR=/tmp/ctrlshiftai_no5_onsite_eval_20261025_rules \
  .venv/bin/python scripts/run_eval.py \
  --input "数据/06_非公开测试集_现场加试/01_非公开测试集_输入_现场提供.xlsx" \
  --out "会话记录"
```

运行结果：30 / 30 题均生成非空回复及 trace，覆盖 29 个会话文件，trace 未记录模型调用；逐题处理耗时合计 157 ms，单题均值约 5.23 ms、中位数 6 ms、最大值 7 ms。非公开集会话文件（N–Z、AA–AP）与公开集文件（A–M）均直接保存在 会话记录/ 根目录。逐题输入、回复和耗时见 自测结果/CtrlShiftAI_赛题05_非公开测评集现场加试逐题结果.xlsx。

本批输入不含标准答案，因此本节只报告运行覆盖、回复落盘和耗时，不计算或声称答案准确率。

7. 已知限制

1. 对话解析是规则实现：常见说法已覆盖，特殊口语、方言或错别字可能无法识别，会走追问或提示，不会静默猜测。
1. 企业名称前面带未登记的前缀词（如「一家」「新来了」之外的说法）时，按另一家企业处理，判未收录。
1. 前端页面没有自动化测试，只做过人工浏览器操作（新建、多轮、切换会话）；宽屏下的整体布局未做视觉检查。
1. 公开集只有 15 题、单次运行，没有重复多次统计耗时波动；非公开集输入不含标准答案，无法据此计算答案一致率。